

# Mémoire 2.0 : la même question, sans les biais

Guillaume Vaudescal · 2026-08-29 · [Guilou001/05-memoire-2.0](#)

Reprise de mon mémoire de maîtrise (*Évaluation empirique d'actifs canadiens par l'apprentissage automatique*, UQAM, décembre 2024) avec les méthodes de 2026 : chaque biais mesuré dans la [version 1](#) est corrigé ici, un par un, et chaque résultat porte maintenant sa probabilité de n'être que du bruit.

Le même contenu en PDF : [rapport/rapport.pdf](#).

**Résultat en une phrase (mesuré, protocole complet).** Une fois l'information réellement disponible au moment de décider, les hyperparamètres choisis hors de la période de test et les coûts payés, **aucun des huit modèles ne bat le portefeuille équipondéré, ni au Canada ni aux États-Unis**. Le meilleur modèle fait 4,1 % net par an avec un ratio de Sharpe, le rendement moyen divisé par la volatilité (annualisé), de 0,31 et un Sharpe déflaté de 0,007 (0,195 en remettant les essais au même horizon, modélisé) ; l'équipondéré canadien fait 11,4 % avec un Sharpe de 0,85. La rotation, la somme mensuelle des variations absolues des poids du portefeuille, atteint 2 à 3 par mois et coûte plus que le signal extrait, exactement le mécanisme décrit par Jensen, Kelly, Malamud et Pedersen (2026).

*English summary.* My 2024 MSc thesis asked whether machine learning fed with macroeconomic data predicts Canadian and US stock returns, and whether long short portfolios built on those predictions make money. This repository re-answers the question with 2026 best practices: real-time information alignment, hyperparameters selected on a pre-test validation window and then frozen, per-stock characteristics (momentum, volatility) interacted with macro factors learned inside each fold, combinatorial purged cross-validation with embargo, net-of-cost portfolios, Newey-West t-statistics, deflated Sharpe ratios and the probability of backtest overfitting. Full-protocol result: net of 10 bp costs, no model beats the equal-weight benchmark in either country (best: Canadian gradient boosting, 4.1 % net CAGR, deflated Sharpe 0.01 vs 0.95 needed); turnover of 2-3 per month costs more than the signal extracted.

## 1. Pourquoi une version 2

La version 1 reproduit le mémoire à l'identique et documente quatre problèmes, chacun mesuré dans [son dépôt](#) : les hyperparamètres étaient choisis sur la période de test ; les variables macroéconomiques étaient alignées un mois en avance sur le rendement à prédire ; plusieurs modèles prédisaient la même valeur pour tous les titres (leurs portefeuilles se réduisaient à l'ordre alphabétique des colonnes) ; et les coûts de transaction étaient à zéro. Or un backtest n'a de valeur que si l'information utilisée était disponible au moment de décider, et que si les frictions sont payées. Ce dépôt reconstruit donc tout le protocole autour de cette exigence, en gardant la question, les données et les familles de modèles du mémoire.

## 2. Ce que la version 2 fait de différent, point par point

Le zoo de modèles reste dans l'esprit du mémoire (ridge, filet élastique, forêt aléatoire, Extra Trees, gradient boosting, petit perceptron), avec deux ajouts de la littérature récente : le **ridge à traits de Fourier aléatoires** de Kelly, Malamud et Zhou (2024), et un **ensemble** (moyenne des prédictions standardisées). Tout est scikit-learn : pas de dépendance fragile.

## 3. La méthode, pas à pas

1. **Construire le panel.** Une ligne = un titre à une date de formation (un 1er de mois). La cible est le rendement du mois qui commence à cette date. Les caractéristiques n'utilisent que des prix antérieurs ; la macro attachée est la dernière publiée. Un test automatique vérifie chacun de ces alignements.

2. **Choisir les réglages, puis les geler.** Chaque famille de modèles essaie sa petite grille sur 2004-2007. Le meilleur réglage est retenu une fois pour toutes : quand la période de test commence, plus rien ne bouge. Chaque essai est compté et son Sharpe de validation conservé, car le nombre d'essais et la variance des Sharpe entre essais entrent tous deux dans le Sharpe déflaté.
3. **Mesurer deux fois.** D'abord en marche avant (réentraînement annuel sur fenêtre croissante, prédictions mensuelles), le protocole lisible ; ensuite en validation croisée purgée combinatoire, le protocole robuste, qui juge chaque modèle sur 28 chemins hors échantillon et alimente la PBO.
4. **Payer les coûts, compter les positions.** Chaque mois, achat du quintile du haut, vente à découvert du quintile du bas (10 titres de chaque côté), poids égaux, 10 pb par unité échangée.
5. **Ne croire un Sharpe que déflaté.** Chaque Sharpe net est accompagné de sa t-stat Newey-West et de son Sharpe déflaté ; la grille entière passe à la PBO, lue contre son repère sous  $H_0$  (0,43 pour sept configurations, `metrics.niveau_nul_pbo`) et non contre 0,50.

#### 4. Les résultats complets (mesurés, walk-forward 2008-2024, nets de 10 pb)

Sept familles de modèles plus l'ensemble, hyperparamètres gelés sur 2004-2007, réentraînement annuel. Dans les tableaux :  $R^2$  HÉ, le  $R^2$  hors échantillon, mesuré contre la prévision zéro (convention Gu, Kelly et Xiu, 2020) ; TCAC, le taux de croissance annuel composé, net de coûts ; DSR, le Sharpe déflaté, la probabilité que le Sharpe survive aux 33 essais réellement menés, les 25 réglages de la grille de validation (comptés dans `models.grid()`) plus les 8 modèles évalués, avec la variance des Sharpe mesurée entre ces essais ; au-dessus de 0,95, on peut y croire. Chiffres copiés de `results/tables/walk_forward_canada.csv` et `results/tables/walk_forward_usa.csv`.

États-Unis (50 titres S&P 500).

Canada (50 titres TSX).




Fig. 1. – Croissance nette, États-Unis

Comment lire cette figure : chaque courbe est la valeur d'un dollar investi début 2008 dans le portefeuille long short net de coûts du modèle, en échelle logarithmique (une pente constante y signifie un taux de croissance constant, et les pertes se lisent aussi bien que les gains) ; la courbe noire tiretée est l'équipondéré long only, le repère à battre. Aucune courbe de modèle ne la rejoint.




Fig. 2. – Croissance nette, Canada

Comment lire cette figure : mêmes conventions que la figure américaine. Trois modèles d'arbres finissent au-dessus d'un dollar, mais loin sous la courbe tiretée de l'équipondéré ; le ridge à traits aléatoires (RFF) détruit la mise dans les deux pays.

Comment lire ces résultats, en cinq constats :

- **Aucun modèle ne bat l'équipondéré, dans aucun des deux pays.** Le meilleur cas est le gradient

boosting canadien : 4,1 % net par an (Sharpe 0,31, t de Newey-West 1,33, DSR 0,007), contre 11,4 % (Sharpe 0,85) pour le simple équipondéré. Aucun DSR n'atteint 0,95 : aucun Sharpe ne survit à la correction du nombre d'essais, une fois la variance entre essais mesurée sur les 33 essais réellement menés plutôt que supposée.

- **La rotation est le tueur.** Les modèles rebrassent 2 à 3 fois le portefeuille chaque mois ; à 10 points

de base, cela coûte 2,5 à 4 % par an, plus que le signal qu'ils extraient. Le ridge à traits aléatoires (le « virtue of complexity » de Kelly, Malamud et Zhou, 2024) est le cas extrême : ses prédictions changent sans cesse, rotation de 3,2, et il finit dernier des deux pays, exactement la mécanique d'échec décrite par Jensen, Kelly, Malamud et Pedersen (2026) et le soupçon de Nagel (2025).

- **La ligne plate du filet élastique américain n'est pas une victoire.** Sa pénalité L1 annule presque

tous les coefficients, ses prédictions deviennent égales entre titres, et le garde-fou anti-classement- alpha-bétique le sort alors du marché : son Sharpe de 0,27 est surtout celui de ne rien faire. Le compte est publié depuis l'audit du 2026-08-29 dans la colonne [mois\\_actifs](#) : **12 mois sur 195**, tous en 2008, dernier rendement non nul en janvier 2009. Un Sharpe qui divise la moyenne de douze mois d'activité par l'écart type de seize ans mesure surtout la longueur de l'inaction ; la figure du Sharpe déflaté le porte à côté du nom du modèle. La v1 aurait affiché ce modèle comme gagnant ; la v2 montre qu'il est vide.

- **Le Canada ressort mieux que les États-Unis** (les arbres y sont tous positifs nets,  $R^2$  HÉ légèrement

positifs), ce qui rejoint l'intuition du mémoire : un marché plus petit, moins arbitré, laisse un peu plus de prévisibilité : les arbres canadiens battent au moins le contrôle momentum/volatilité (Sharpe -0,16), le classement mécanique sans apprentissage. Mais « un peu plus » reste loin du repère passif, et la validation croisée purgée reprend l'avantage apparent : sur les 28 chemins CPCV, aucune boîte n'est entièrement à droite de zéro ; celle des Extra Trees canadiens et celle du gradient boosting américain sont franchement

à gauche, et trois autres (RFF canadien, MLP et RFF américains) finissent au ras de zéro (figures ci-dessous). La PBO ressort à 0,35 au Canada et 0,09 aux États-Unis, contre un repère de 0,43 sous H0 pour sept configurations ([results/tables/pbo\\_canada.json](#), [pbo\\_usa.json](#)) : le classement interne des modèles est plutôt stable d'un découpage à l'autre, ce qui ne dit rien de leur niveau, faible partout. Ces deux nombres remplacent le 0,11 et le 0,01 publiés jusqu'à l'audit du 2026-08-29, obtenus en donnant à la CSCV les 28 chemins CPCV, qui se chevauchent : avec deux blocs de test sur huit, chaque bloc est jugé dans sept chemins, si bien que les deux moitiés d'une partition portaient sur les mêmes mois et que la PBO s'effondrait. La matrice porte désormais un Sharpe par bloc DISJOINT ; l'écart est reproduit sur du bruit pur par [test\\_pbo\\_colonnes\\_chevauchantes\\_ecrase\\_la\\_mesure](#).

• **Le petit  $R^2$  positif des arbres n'est pas du talent de classement.** Un test placebo le montre : en mélangeant aléatoirement les cibles (plus aucun lien entre variables et rendements), les Extra Trees canadiens gardent un  $R^2$  hors échantillon de +0,013, comparable au +0,014 obtenu sur les vraies cibles ([results/tables/placebo.csv](#)). En effet, le  $R^2$  à la Gu-Kelly-Xiu se mesure contre la prévision zéro : un modèle très régularisé qui prédit simplement « les rendements sont en moyenne positifs » marque ces points sans classer les titres. Le portefeuille long short, qui neutralise ce niveau moyen, remet les compteurs à leur vraie valeur : autour de zéro.




Fig. 3. – Sharpe déflaté par modèle

Comment lire cette figure : un trait horizontal par modèle donne son ratio de Sharpe annualisé net sur 2008-2024, et le trait tireté orange marque le seuil SR0, le meilleur Sharpe qu'on attend de la seule chance après les 33 essais menés (Bailey et López de Prado, 2014). La bande grise de droite porte deux probabilités, pas des Sharpe, d'où son fond distinct et l'arrêt des graduations avant elle : le Sharpe déflaté mesuré, et sa variante à horizon égal. Le meilleur modèle canadien plafonne à 0,31 de Sharpe contre un seuil de 0,91, et le meilleur américain à 0,27 contre 0,92 : c'est cet écart, et non un défaut de calcul, qui laisse le Sharpe déflaté à 0,007 au mieux.

Le seuil pointillé gris est la même barre calculée après avoir remis les essais au même horizon que le Sharpe jugé. Les 25 réglages de la grille sont mesurés sur 48 mois de validation, les 8 familles sur 196 mois de test ; comme la variance d'échantillonnage d'un Sharpe décroît en  $1/T$ , les essais courts gonflent la dispersion, donc le seuil, donc écrasent le Sharpe déflaté, et le biais joue en faveur du verdict de ce dépôt. La correction (statut modélisé, [metrics.variance\\_essais\\_a\\_l\\_horizon](#)) ramène le seuil de 0,91 à 0,52 et le meilleur Sharpe déflaté de 0,007 à 0,195. Le verdict tient dans les deux lectures : 0,195 reste très loin de 0,95.

La version précédente de cette figure portait le Sharpe déflaté lui-même sur un axe de 0 à 1. Comme toutes les valeurs valaient au plus 0,007, les seize barres étaient invisibles et l'étiquette « 0,00 » se répétait seize fois : la figure était vraie et ne montrait rien. Chiffres : colonnes [sharpe\\_net](#), [dsr](#) et [sharpe\\_seuil\\_dsr](#) de [results/tables/walk\\_forward\\_canada.csv](#) et [walk\\_forward\\_usa.csv](#).




Fig. 4. – Sharpe CPCV, Canada

Comment lire cette figure : chaque boîte est la distribution des Sharpe nets du modèle sur les 28 chemins de la validation croisée purgée (avec purge et embargo) ; la boîte va du premier au troisième quartile, le trait interne est la médiane, les moustaches couvrent le reste de la distribution, les cercles isolent les chemins atypiques, et la ligne verticale grise marque zéro. Une stratégie robuste aurait sa boîte entière à droite de zéro ; aucune ne l'est, et celle des Extra Trees est entièrement à gauche. Le filet élastique, dont les prédictions deviennent constantes sur ces chemins (aucune position, Sharpe non calculable), est retiré de la figure et signalé en note.




Fig. 5. – Sharpe CPCV, États-Unis

Comment lire cette figure : mêmes conventions que la figure canadienne. Le gradient boosting, pourtant meilleur modèle canadien en marche avant, a ici sa boîte entièrement à gauche de zéro : ce qu'un seul chemin de backtest donne, la distribution des chemins le reprend.

En une phrase : **avec l'information réellement disponible, des réglages choisis sans tricher et des coûts payés, la prédiction mensuelle macro + momentum ne bat pas un portefeuille naïf sur 2008-2024** ; c'est la réponse, plus modeste mais solide, à la question du mémoire.

## 5. Reproduire

```
uv sync --locked --all-extras          # environnement verrouillé (Python 3.12, pandas
3, scikit-learn 1.9)
uv run pytest                          # 21 tests : alignements, purge, portefeuille,
contrôle, métriques
uv run python scripts/fetch_data.py     # prix Yahoo ; déposer macro_data.csv (LCDMA)
et Fred-MD.csv à la main
uv run m2 run --country both            # protocole complet ; --fast pour un essai en 2
minutes
uv run m2 figures --country both
uv run python scripts/placebo.py        # test placebo (cibles mélangées) -> results/
tables/placebo.csv
uv run python scripts/make_dsr_figure.py # figure du Sharpe déflaté par modèle
```

Les chiffres des tableaux ci-dessus viennent de [results/tables/walk\\_forward\\_canada.csv](#) et [results/tables/walk\\_forward\\_usa.csv](#), le placebo de [results/tables/placebo.csv](#), la PBO de [results/tables/pbo\\_canada.json](#) et [pbo\\_usa.json](#) ; aucun chiffre du README n'est retapé à la main.

## 6. Limites, avec leur statut

## 7. Références

Gu, Kelly et Xiu (2020, RFS) ; Kelly, Malamud et Zhou (2024, JF) et la réponse de Nagel (2025) ; Jensen, Kelly, Malamud et Pedersen (2026, RFS) ; López de Prado (2018), Bailey et López de Prado (2014) ; Arian, Norouzi et Seco (2024, KBS) ; Goulet Coulombe et Göbel (2024) ; Bryzgalova, Lerner, Lettau et Pelger (2025, RFS). Données : Yahoo Finance (usage personnel), LCDMA (Fortin-Gagnon, Leroux, Stevanovic et Surprenant, 2022), FRED-MD (McCracken et Ng, 2016).

Code MIT ; texte et figures CC BY 4.0. Guillaume Vaudescal, avec le dépôt frère [memoire-uqam-2024](#) pour la version reproduite du mémoire.